

Agentic RL 综述与方法巧思报告 (截至 2026-03-03)

日期: 2026-03-03

目标: 聚焦 agentic RL 相关 survey, 提炼“什么方法更好、哪里有巧思”

一、重点 survey (优先阅读)

- 1) The Landscape of Agentic Reinforcement Learning for LLMs: A Survey
arXiv:2509.02547 (v4: 2026-01-24)
- 2) Reinforcement Learning Foundations for Deep Research Systems
arXiv:2509.06733 (TMLR 2026)
- 3) A Survey of Reinforcement Learning for Large Reasoning Models
arXiv:2509.08827
- 4) Reinforcement Learning Meets Large Language Models
arXiv:2509.16679

二、方法图谱

- 1) 问题建模: 将 agent 执行视为 POMDP (状态=轨迹历史, 动作=文本+工具, 奖励=质量+成本+安全)。
- 2) 常见训练范式:
 - PPO/GRPO 在线优化
 - DP0/IP0/ORPO 偏好优化
 - RLVR 可验证奖励驱动
 - Offline warm-start + Online refinement 混合范式

三、方法巧思 (最有用)

- 1) 分层 credit assignment: 把长任务拆成子目标并给中间奖励, 降低方差。
- 2) PRM + 结果奖励混合: 同时优化过程正确性和最终正确性, 减少投机路径。
- 3) 可验证器优先奖励设计 (RLVR): 在代码/数学任务中稳定性最好。
- 4) 工具动作与文本动作解耦: 降低动作耦合导致的不稳定。
- 5) 成本约束入目标函数: 显式约束 token、调用次数和时延, 便于生产部署。
- 6) 离线轨迹筛选 + 在线难例挖掘: 提高 rollout 信息密度和训练性价比。

四、场景化建议

- 1) 代码/数学: RLVR + 分层奖励 + offline/online 混合。
- 2) 开放域 research agent: 分层奖励 + PRM + 成本约束。
- 3) 多工具复杂编排: 动作解耦 + 安全/成本约束优化。
- 4) 小算力团队: 偏好优化 warm start + 小步在线 RL。

五、推荐配方

- 1) SFT/偏好优化初始化。
- 2) 尽可能使用可验证奖励。
- 3) 分层任务拆解与中间奖励。
- 4) 成本与时延约束。
- 5) 在线阶段聚焦难例采样。